

Proposta de TCC1: Grafos de conhecimento e Agentes

Eduardo da Costa dos Santos

Março de 2026

Aluno: Eduardo da Costa dos Santos

Orientador: Cezar Augusto Tacla

1. Contexto, Problemática e Justificativa

As atividades do Programa de Educação Tutorial (PET) possuem elevada relevância, mas suas informações estão fragmentadas na web, dificultando o acesso e a colaboração. Este trabalho busca responder: como extrair e centralizar dados heterogêneos para criar uma base de conhecimento semanticamente enriquecida? A solução proposta é uma arquitetura que integra agentes artificiais, ontologias e grafos. A proposta justifica-se por substituir processos de coleta manual e armazenamento tabular por uma infraestrutura, capaz de dar significado a dados não estruturados, promovendo transparência e visibilidade ao impacto dos grupos PET no Brasil.

2. Objetivos

O objetivo geral é propor e validar uma arquitetura de software (agentes, ontologias e grafos) para a coleta e estruturação de dados do PET.

1. Modelar a ontologia de domínio do ecossistema PET.
2. Desenvolver agentes (*scrapers*) para extração web.
3. Implementar a persistência em banco de dados em grafos.
4. Construir as camadas de integração (*back-end* e *front-end*).
5. Avaliar a arquitetura em duas frentes metodológicas: (1) a capacidade de extração dos agentes (medida por métricas de precisão e revocação frente a um padrão de referência); e (2) a eficácia na recuperação de informações, comparando a capacidade de inferência da ontologia contra uma abordagem de armazenamento de dados simplificada.

3. Fundamentação Teórica e Trabalhos Relacionados

Com base em Guarino (1998), este trabalho adota a abordagem de *ontology-driven information systems*

para modelar os dados dos grupos PET. Na engenharia de software, uma ontologia não atua apenas como um dicionário de termos, mas como um artefato que utiliza axiomas lógicos para restringir e definir computacionalmente o significado de um vocabulário. Essa característica a diferencia de esquemas de dados baseados apenas em estruturação sintática, como arquivos JSON padrão, que organizam atributos e valores sem definir as premissas lógicas que os conectam.

Para armazenar e consultar o conhecimento estruturado pela ontologia, a arquitetura proposta emprega bancos de dados em grafos. Essas estruturas utilizam os conceitos de nós, arestas e propriedades para representar informações de forma nativamente interconectada. Em tempo de execução, a ontologia opera em conjunto com o grafo para processar consultas intensionais e realizar inferências. Na prática, testes demonstram que bancos orientados a grafos (como o Neo4j) superam bancos relacionais tradicionais (como o PostgreSQL) no tempo de resposta para buscas de caminhos em profundidade. Isso ocorre devido ao conceito de adjacência livre de índices, que substitui as custosas operações de *JOIN* Higa (2016), permitindo ao sistema deduzir e recuperar as conexões entre as atividades dos grupos de forma eficiente.

A alimentação dessa base de conhecimento depende da coleta autônoma na web, tarefa delegada a agentes artificiais. Na literatura clássica, um agente é um sistema computacional situado em um ambiente, capaz de perceber mudanças e atuar de forma autônoma para alcançar seus objetivos. No contexto da extração de dados, ferramentas de *scraping* tradicionais exigem manutenção constante face a alterações na estrutura HTML dos sites. Para contornar essa limitação, trabalhos como o de Sousa et al. (2025) demonstram agentes guiados por Grandes Modelos de Linguagem (LLMs) que operam em ciclos iterativos (observar, planejar, agir) para extrair dados em estruturas dinâmicas. Contudo, enquanto o armazenamento final dessas coletas costuma limitar-se a formatos tabulares, este trabalho

avança ao submeter os dados brutos capturados pelos agentes à modelagem ontológica e à persistência nativa em grafos.

4. Metodologia e Validação

A metodologia segue um fluxo contínuo de engenharia e avaliação, estruturado nas seguintes etapas:

1. **Revisão e Modelagem:** Pesquisa teórica e especificação da ontologia de domínio, estabelecendo conceitualmente as classes, propriedades e relacionamentos do ecossistema PET.
2. **Desenvolvimento dos Agentes:** Construção de rotinas automatizadas (*web scraping*) para a extração de dados brutos em fontes web heterogêneas e desestruturadas.
3. **Estruturação e Persistência em Grafos:** Etapa de limpeza e transformação dos dados capturados. As informações serão instanciadas segundo as definições de classes e relações advindas da ontologia de domínio, estruturadas rigorosamente no formato de triplas (sujeito, predicado, objeto) e persistidas no banco de dados em grafos.
4. **Camada de Integração e Interface:** Construção do *back-end* (responsável por traduzir requisições do usuário em consultas a grafos) e da aplicação *front-end*.
5. **Validação e Estudo de Caso:** O sistema será avaliado sob um protocolo de testes estruturado em duas frentes metodológicas:
 - **Avaliação da Capacidade de Extração:** Medição da aptidão do sistema em capturar as informações *existentes* com precisão. Será construído um padrão de referência a partir da coleta manual de dados em páginas institucionais e redes sociais (como o Instagram) dos grupos PET. O objetivo é analisar o conteúdo para identificar exatamente as atividades reais e suas relações. O mapeamento poderá contar com o apoio de *Large Language Models* (LLMs), desde que submetido a validação humana obrigatória. O desempenho dos agentes será avaliado comparando os dados extraídos automaticamente contra este padrão, utilizando as métricas de Precisão (*Precision*) e Revocação (*Recall*).
 - **Avaliação da Recuperação de Informações:** Medição de quão bem o sistema responde a consultas utilizando os dados estruturados. O objetivo é analisar o ganho obtido pela estruturação formal com a ontologia em contraste com

um *schema* mais relaxado (como uma representação em JSON, sem semântica formal), identificando situações em que a abordagem simples não conseguiria inferir a resposta correta. Serão elaboradas *queries* em português, acompanhadas de suas respectivas respostas esperadas (referência), para avaliar tanto a qualidade dos resultados quanto a dificuldade comparativa na construção das consultas. Os testes ocorrerão em três níveis:

- (a) **Simples:** Consultas diretas (ex: “*Quais PETs realizaram atividades de ensino?*”);
- (b) **Com uso de hierarquia:** Consultas que exigem a compreensão de classes e subclasses (ex: “*Quais atividades ocorreram em 2024?*”);
- (c) **Com relacionamentos complexos:** Consultas que demandam cruzamentos avançados entre os nós (ex: “*Quais PETs compartilham os mesmos tipos de atividades?*”).

5. Viabilidade, Resultados e Entregáveis (TCC1)

O projeto possui cronograma viável, desenvolvido no período matutino para conciliar com disciplinas e estágio. Ao fim do TCC 2, entregará-se o sistema funcional validado. Para a disciplina de TCC 1, os entregáveis são: (1) a fundamentação teórica; (2) a modelagem conceitual inicial da ontologia; (3) a especificação da arquitetura; e (4) um protótipo do *script* de coleta.

Referências

- Guarino, N. (1998). Formal ontology and information systems. In *Formal Ontology in Information Systems: Proceedings of the First International Conference (FOIS'98), June 6-8, Trento, Italy*, volume 46, pages 3–15. IOS press.
- Higa, G. T. A. (2016). Bancos de dados orientados a grafos: Uma comparação conceitual e de performance com as ferramentas neo4j e postgresql. Pôster acadêmico. Instituto de Matemática e Estatística – Universidade de São Paulo (IME-USP).
- Sousa, J. V. C. N. d., Mingardo, L. M., Freire, C. E. T., Traina, A. J. M., and Junior, C. T. (2025). Agente autônomo guiado por llm para extração de notícias. In *Proceedings of the 40th Brazilian Symposium on Data Bases (SBBDB)*, Fortaleza, CE, Brazil.